

我是菜鸟www

博客等级 码龄6年

110 253 1260 425

原创 点赞 收藏 粉丝

关注

私信

文心大模型

[百度文心大模型4.5系列正式开源]

国内首发平台GitCode

现已开放下载

探索模型库

热门文章

生信分析-TBtools绘制热图 56978

WGCNA加权基因共表达网络分析（1）简介、原理 32645

FastQC结果解读 30111

生信分析-本地BLAST 24950

生信分析-利用TBtools提取序列 14508

分类专栏

Python学习 12篇

生物信息学 10篇

AI绘图 1篇

自己看 1篇

上一篇：ASCII码表

下一篇：质控参数简介

最新评论

生信分析-本地BLAST
shubaiwww: 点击cmd显示我的电脑不可以操作 怎么办啊

WGCNA加权基因共表达网络分析（1）...
qq_48794924: 请问和临床性状相关性，比如生存状态是和生存相关还是死亡相关透...

生信分析-TBtools绘制热图
weixin_69023491: 你好 请问用TBtools做热图可以让数据带显著性星号吗 如果可以...

WGCNA加权基因共表达网络分析（1）...
四七三十八: 非常透彻！！

生信分析-TBtools绘制热图
提与: 如果字体有下标怎么办

最新文章

利用Python解决生物问题：锁定fasta序列文件中感兴趣的motif位置

Python-类和对象之构造函数

利用Python解决生物问题：批量对应转录本-基因名

FastQC结果解读

原创 我是菜鸟www 于 2021-02-10 14:32:05 发布 阅读量3w 收藏 186 点赞数 27

CC 4.0 BY-SA版权



GitCode 开源社区 文章已被社区收录

加入社区

拿到原始数据后我们采用FastQC程序进行质控，看原始数据质量情况，fastqc会生成一个html结果报告，根据图形化界面，我们可以判断下机数据情况是否符合分析要求，

查看html格式的结果报告。结果分为如下几项：

- 绿色的"PASS"
 - 黄色的"WARN"
 - 红色的"FAIL"
- attention:**当出现黄色时说明需要查看结果



FastQC Report

周三 10 2月 2021
DRR125491_1.fastq


Summary

- Basic Statistics
- Per base sequence quality
- Per sequence quality scores
- Per base sequence content
- Per sequence GC content
- Per base N content
- Sequence Length Distribution
- Sequence Duplication Levels
- Overrepresented sequences
- Adapter Content

Basic Statistics

Measure	Value
Filename	DRR125491_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	4051944
Sequences flagged as poor quality	0
Sequence length	35-301
%GC	50

Per base sequence quality



1. Basic Statistics

Basic statistics是该fastq一些基本信息：

- Filename:文件名
- File type: 文件类型
- Encoding：测序平台的版本和相应的编码版本号，用于计算Phred反推error P时用
- Total Sequences: 输入文本的reads的数量
- Sequence length: 测序长度
- %GC: GC含量，表示整体序列的GC含量，由于二代测序GC偏好性高，且深度越高，GC含量会越高。



Basic Statistics

Measure	Value
Filename	DRR125491_1.fastq
File type	Conventional base calls
Encoding	Sanger / Illumina 1.9
Total Sequences	4051944
Sequences flagged as poor quality	0
Sequence length	35-301
%GC	50

2.Per base sequence quality



我是菜鸟www

关注

27



GO>

登录后您可以享受以下权益：

- 免费复制代码
- 和博主大V互动
- 下载海量资源
- 发动态/写文章/加入社区

立即登录

2022年 18篇 2021年 92篇
2020年 4篇



广告 X

推荐新用户

最多可获45%现金奖励

成为天翼云·云推官，享专属福利
月奖励最高可达10万元


目录

[查看html格式的结果报告。结果分为如下...](#)

1. Basic Statistics
2. Per base sequence quality
3. Per Sequence Quality Scores
4. Per Base Sequence Content
5. Per Sequence GC Content
6. Per base N content
7. Sequence Length Distribution
8. Sequence Duplication Levels
9. Overrepresented sequences
10. Adapter Content

收起 ^

- 在人体小孩位置所有测序的测序质量统计，在体（蓝色）是2070~1270达100质量分布，S101 Del（肺炎）是1070~9070达100质量分布，蓝色表示平均数，红色为中位数。
- 一般要求所有位置的10%小于20，即最多允许该位置10%的序列低于Q20，即90%的序列的碱基质量都大于Q20，即90%的序列碱基错误率不超过99%。当任何碱基质量低于10，或者任何中位数低于25时报WARN,需注意；当任何碱基质量低于5或者任何中位数低于20报FAIL。




碱基质量值Q

- 碱基质量值，Q，即每个碱基的正确识别率，是衡量测序质量的重要标准
- Q值通过测序Phred值计算而得，公式为： $Q\text{-score} = -10 \times \lg P$
- Phred值：不正确的碱基识别率，在碱基识别过程中通过一种概率模型计算得到，该模型可准确预测碱基识别的错误率
- 碱基质量值越高表明碱基识别越可靠，准确度越高
- Q20与Q30的含义：
 - 【1】Q20为每100个碱基中会有一个识别错，即正确识别率为2个9，99%，当Phred = 20 时，碱基识别出错率为1/100，碱基识别正确率为99%， $Q\text{-score} = -10 \times \lg 10^{-2}=20$
 - 【2】Q30为每1000个碱基中会有一个识别错，正确识别率为3个9，99.9%，当Phred = 30 时，碱基识别出错率为1/1000，碱基识别正确率为99.9%， $Q\text{-score} = -10 \times \lg 10^{-3}=30$
- Q30 > 90%,即碱基质量值 ≥ Q30的碱基所占百分比 ≥ 90%

3.Per Sequence Quality Scores


- 每条reads的quality的均值的分布
- 横轴表示Q值，纵轴表示每个值对应的read数目，当测序结果主要集中在高分中，证明测序质量良好
- 当峰值小于27（错误率0.2%）时报"WARN"，当峰值小于20（错误率1%）时报"FAIL"



4 Per Base Sequence Content


- 对所有reads的每一个位置，统计ATCG四种碱基（正常情况）的分布，用于检查是否有AT,GC分离现象
- 横轴为碱基长度分布，纵轴表示百分比，图中4条线分别代表A，C，T，G在每个位置上的平均含量
- 由于测序平台及测序长度不同，以及测序仪开始状态不稳定经常出现前后波动情况

- 好的样本中四条线应该平行且接近。当部分位置碱基的比例出现bias时，即四条线在某些位置纷乱交织，往往提示我们有 overrepresented sequence 的污染。当所有位置的碱基比例一致的表现出bias时，即四条线平行但分开，往往代表文库有bias (建库过程或本身特点)，或者是测序中的系统误差。
- 在碱基含量分布图，前几个碱基可能会出现较大波动，这是由于随机引物扩增偏差原因造成的
- 当任一位置的A/T比例与G/C比例相差超过10%，报"WARN"；当任一位置的A/T比例与G/C比例相差超过20%，报"FAIL"




5. Per Sequence GC Content


- 统计reads的平均GC含量的分布
- 红线是实际情况，蓝线是理论分布（正态分布，均值不一定在50%，而是由平均GC含量推断的）
- 曲线形状的偏差往往是由于文库的污染或是部分reads构成的子集有偏差（overrepresented reads）。形状接近正态但偏离理论分布的情况提示我们可能有系统偏差
- 偏离理论分布的reads超过15%时，报"WARN"；偏离理论分布的reads超过30%时，报"FAIL"。



6. Per base N content


- 当出现测序仪不能分辨的碱基时会产生N，横轴为碱基分布，纵轴为N比率
- 当任一位置N的比率超过5%报WARN，超过20%报FAIL






7. Sequence Length Distribution

- reads长度的分布
- 理论上每次测序仪测出的read长度是一致的，但是由于建库等因素通常会导致一些小片段，reads长度不一致时报"WARN"；当有长度为0的read时报"FAIL"



8. Sequence Duplication Levels



- 统计序列完全一致的reads的频率，横坐标是duplication的次数，纵坐标是duplicated reads的数目，以unique reads的总数作为100%。
- 上图的情况中，相当于unique reads数目 ~ 20%的reads是观察到两个重复的，~ 3%是观察到三次重复的，依此类推
- 一般测序深度越高，越容易产生一定程度的重复序列
- 如果原始数据很大（事实往往如此），做这样的统计将非常慢，所以fastqc中用fq数据的前200,000条reads统计其在全部数据中的重复情况。重复数目大于等于10的reads被合并统计，大于75bp的reads只取50bp（不知道怎么选的）进行比较。但由于reads越长越不容易完全相同（由测序错误导致），所以其重复程度仍有可能被低估。
- 当非unique的reads占总数的比例大于20%时，报"WARN"；当非unique的reads占总数的比例大于50%时，报"FAIL"

9. Overrepresented sequences

- 如果有某个序列大量出现，就叫做over-represented。
- fastqc的标准是占全部reads的0.1%以上。和上面的duplicate analysis一样，为了计算方便，只取了fq数据的前200,000条reads进行统计，所以有可能over-represented reads不在里面。而且大于75bp的reads也是只取50bp。如果命令行中加入了-c contaminant file，出现的over-represented sequence会从contaminant_file里面找匹配的hit（至少20bp且最多一个mismatch），可以给我们一些线索。
- 当发现超过总reads数0.1%的reads时报"WARN"，当发现超过总reads数1%的reads时报"FAIL"。




Overrepresented sequences

No overrepresented sequences

https://blog.csdn.net/qz_44520665

10.Adapter Content

- 横轴表示碱基位置，纵轴表示百分比
- 当fastqc分析时没有选择参数-a adapter list时，默认使用图例中的4种通用adapter序列进行统计。
- 若有adapter残留，后续必须去接头



本文参考：

[FastQC结果简介](#)

[FastQC处理二代测序原始数据的质量结果解读](#)

更多可参考：<http://www.bioinformatics.babraham.ac.uk/projects/fastqc/Help/>

打工人搞副业别卷时间！AI自动化工具让你睡觉时都在赚钱

从LLM技术原理到多模态应用开发！三天掌握AI获客/数字人开发/接单渠道，开启第二职业收入管道

FastQC结果简介 热门推荐

gateswell 的博客  2万+

拿到原始数据后我们采用fastqc程序进行质控，看原始数据质量情况，fastqc会生成一个html结果报告，根据图形化界面，我们可以判断下机数据情况是否...

一文掌握fastqc使用及结果解读_fastqc报告怎么看

6-26

<https://www.bioinformatics.babraham.ac.uk/training.html>，简单来说，fastqc就是用来生成高通量测序原始数据可交互式质控报告的工具，而对建库方式、文库...

scRNA_SMARTseq2_smart-seq2分析流程资源-CSDN文库

6-21

输出压缩整理的FASTQ,修剪报告和fastqc报告。Fastqscreen 流水线在修剪后的读数上运行FastQ屏幕,并生成更多的QC报告。映射 该管道使用HISAT2...

RNA-seq——二、sra数据下载、fastqc与质量控制

Dzfly  2256

sra数据下载、fastqc、multiqc、质量控制

一文掌握fastqc使用及结果解读

weixin_47195452 的博客  1773

每个tile测序情况，横轴表示碱基位置，纵轴表示tile的index编号，这个图主要是为了防止在测序过程中某些tile受到不可控因素的影响而出现测序质量偏低...

02-转录组上游分析-数据质控、过滤_fastqc软件产生的质控报告必须要运...

6-28

fastqc-l6-o./".fq.gz #按esc:wq nohup bash qc.sh>qc.log 查看命令 cat qc.sh # 如何知道运行完了? cat qc.log # 质控的结果给每个fq文件生成一个zip文件和...

使用FastQC进行测序数据质量控制

6-17

FastQC是一个java程序,能够用于给出测序数据的QC报告,报告中会同时给出上述几个方面的数据图,并提示原来的数据可能还存在着哪些问题,它可以很好...

小白学生信使用fastqc分析文件2

qq_51575505 的博客  170

3、转换 SRA 为 FASTQ: fastq-dump --split-files SRR1234567 # 输出为 FASTQ。4、直接下载并转换: fastq-dump --split-files --skip-technical SRR1234...

fcQCA模糊集定性比较分析法-学习笔记 最新发布

王斯 的博客  1315

是一种结合了定性和定量元素的研究方法，用于分析中小样本数据中的复杂因果关系。

安装fastqc_FastQC测序数据质量评估

6-29

安装fastqc_FastQC测序数据质量评估 C知道前往体验 > 展开 最近总有童鞋问,拿到的测序数据,我怎么知道或者评判质量好坏呢,别着急,今天给你推荐一款...

Hemberg-lab单细胞转录组数据分析(三)_单细胞fastqc输出html和zip-CSDN...

6-5

如果文件很多,一个个看比较麻烦,可以试试整合QC质控**结果**的利器——MultiQC。 移除接头和低质量碱基 TrimGalore!工具是对cutadapt软件的封装,用于移...

FastQC:用于高通量测序数据的质量控制分析工具 05-17
快速质量控制 **FastQC**是一个旨在发现高通量测序数据集中潜在问题的程序。 它以fastq或bam格式对一个或多个原始序列文件运行一组分析,并生成一份...

FastQC使用与结果详细解读 win_win223的博客 1万+
FastQC的使用与结果详细解读

FastQC结果详解 weixin_30398227的博客 1274
REF https://www.plob.org/article/5987.html 解压后, 查看html格式的**结果报告**。**结果**分为如下几项: **结果**分为绿色的"PASS", 黄色的"WARN"和红色的"F...

fastQC 质控结果解读 weixin_30413739的博客 1076
参考网址: https://zhuanlan.zhihu.com/p/20731723 转载于:https://www.cnblogs.com/lmt921108/p/7442525.html

生信质控分析-FastQC 01-13
生物信息分析基础软件, 高通量测序, 主要用于做质控分析

在终端运行FASTQC, 进行测序解读质量评估 12-01
FASTQC是一个非常流行的工具, 用于初步分析和检查高通量测序...5. **查看**报告****：执行完上述命令后, 会在指定的output_directory目录下生成一个名为...

MultiQC:将来自多个样本的生物信息学分析的结果汇总到一个报告中 03-09
将多个样本的生物信息学**结果**汇总到一个**报告**中 在查找和 MultiQC是一种工具, 用于创建具有交互式图表的单个**报告**, 以对多个样本进行多种生物信息学...

fastqc-bioinformatics 04-28
评价生物信息测序序列的质量, 用于生物信息学分析之前的一个质控

guo-cheng#Learning-notes-2021#从头学习转录组之FastQC数据质控报告的详细解读1 07-25
2. Per base sequence quility: 每个测序read上各碱基质量 3. Per sequence quility scores: 每条序列质

fastqc-v0.12.1-个人学习 01-02
值得注意的是, **FastQC**的分析**结果**应该结合实验的具体设计和预期目的来综合判断。例如, 某些特定类型的实验可能会产生看似有问题但实际上合理的数...

数据的质量控制软件——fastQC 刘永鑫的博客——宏基因组公众号 1万+
本文转载自"计算表观遗传学",已获授权。编者按目前的高通量测序技术可以在单次运行中产生数亿个序列。在分析此序列以得出生物学结论之前, 应该执...

转录组之质量控制 (FastQC) [学习笔记通俗易懂] qq_74093550的博客 1万+
FastQC是一个用于高通量序列数据的质量控制程序。**FastQC**可以读取并分析多种格式的序列数据, 并且可以以交互的形式来检查几种不同的质量**结果**, ...

生信软件 | FastQC (质量控制, 查看测序质量) Baimoc 1万+
下载与安装下载地址 http://www.bioinformatics.babraham.ac.uk/projects/download.html#fastqc 安装unzip fastqc.zip使用修改可执行文件权限sudo chmod ...

fastqc帮助 weixin_45066533的博客 862
Basic Statistics模块为分析的文件生成一些简单的组合统计信息。文件名:被分析的文件名原始文件名文件类型:表示文件似乎包含实际的基本调用还是必须...

关于我们 招贤纳士 商务合作 寻求报道 400-660-0108 kefu@csdn.net 在线客服 工作时间 8:30-22:00

公安备案号11010502030143 京ICP备19004658号 京网文〔2020〕1039-165号 经营性网站备案信息 北京互联网违法和不良信息举报中心

家长监护 网络110报警服务 中国互联网举报中心 Chrome商店下载 账号管理规范 版权与免责声明 版权申诉 出版物许可证 营业执照

©1999-2025北京创新乐知网络技术有限公司